

# BÀI TẬP THỰC HÀNH

## CƠ SỞ PHÂN TÍCH DỮ LIỆU LỚN DÙNG PYSPARK

Tài liệu thực hành dùng với Jupyter Notebook / Google Colab / Spark local

### 1. Mục tiêu

- Khởi tạo và sử dụng SparkSession, SparkContext trong PySpark.
- Hiểu RDD, partition, transformation, action và lazy evaluation.
- Xử lý dữ liệu văn bản bằng RDD: map, flatMap, filter, reduceByKey, sortByKey.
- Đọc, làm sạch và phân tích dữ liệu bằng Spark DataFrame và Spark SQL.
- Xây dựng pipeline Machine Learning cơ bản bằng pyspark.ml.
- Biết khi nào nên dùng Spark thay cho Pandas và tránh collect()/toPandas() trên dữ liệu lớn.

### 2. Dữ liệu sử dụng

| Tập dữ liệu              | Mục đích                                 |
|--------------------------|------------------------------------------|
| Complete Shakespeare.txt | RDD, xử lý văn bản, Word Count           |
| Fifa2018_dataset.csv     | DataFrame, Spark SQL, phân tích tổng hợp |
| 5000_points.txt          | K-Means clustering                       |
| spam.txt / ham.txt       | Phân loại văn bản spam/ham               |
| people.csv               | Bài tập DataFrame bổ sung                |
| Movie ratings.csv        | Bài tập mở rộng về dữ liệu đánh giá      |

## BÀI 1 - LÀM QUEN VỚI APACHE SPARK VÀ PYSPARK

### Bài 1.1. Khởi tạo Spark

```
from pyspark.sql import SparkSession
```

```
spark = SparkSession.builder \
    .appName('BigDataFundamentals') \
    .master('local[*]') \
    .getOrCreate()
```

```
sc = spark.sparkContext
```

1. In phiên bản Spark.
2. In Python version.
3. In master.
4. Xác định số core Spark có thể sử dụng.
5. In tên ứng dụng hiện tại.

**Câu hỏi:** SparkSession và SparkContext khác nhau như thế nào?

**Câu hỏi:** local[\*] có ý nghĩa gì?

### Bài 1.2. Parallel Collection

```
numbers = list(range(1, 101))
```

6. Chuyển danh sách thành RDD.
7. Đếm số phần tử.
8. Hiển thị 10 phần tử đầu tiên.
9. Tính tổng từ 1 đến 100.
10. Tìm số lớn nhất và nhỏ nhất.

### Bài 1.3. Map và Filter

11. Tạo RDD chứa bình phương của mỗi phần tử.
12. Lấy các số chia hết cho 3.
13. Lấy các số chia hết cho 5.
14. Lấy các số chia hết cho cả 3 và 5.

**Câu hỏi:** Giải thích sự khác nhau giữa `rdd.map(...)` và hàm `map(...)` của Python.

### Bài 1.4. Transformation, Action và Lazy Evaluation

```
rdd = sc.parallelize(range(1, 1000000))  
result = rdd.filter(lambda x: x % 2 == 0).map(lambda x: x * x)
```

15. Spark đã thực sự tính toán result chưa?
16. Điều gì xảy ra khi gọi `result.take(10)`?
17. Xác định transformation và action.
18. Giải thích lazy evaluation.

## BÀI 2. XỬ LÝ DỮ LIỆU PHÂN TÁN VỚI RDD

### Bài 2.1. Đọc dữ liệu Shakespeare

```
text_rdd = sc.textFile('Datasets/Complete Shakespeare.txt')
```

19. Đếm số dòng.
20. Hiển thị 10 dòng đầu.
21. Đếm số partition.
22. Thử `repartition/coalesce` với 2, 4 và 8 partition.

**Câu hỏi:** partition có vai trò gì trong xử lý song song?

### Bài 2.2. Word Count

23. Tách từng dòng thành các từ bằng `flatMap`.
24. Chuyển mỗi từ thành cặp (word, 1).
25. Dùng `reduceByKey` để đếm.
26. Hiển thị 20 từ xuất hiện nhiều nhất.

### Bài 2.3. Làm sạch văn bản

27. Chuyển về chữ thường.

28. Loại dấu câu.
29. Loại từ dài dưới 3 ký tự.
30. Loại stopwords.
31. Tìm 20 từ phổ biến nhất sau làm sạch.

**Bài 2.4. Phân tích chiều dài từ**

| Nhóm       | Số lượng |
|------------|----------|
| 1-4 ký tự  | ...      |
| 5-8 ký tự  | ...      |
| >= 9 ký tự | ...      |

**Bài 2.5. Transformation nâng cao**

32. Thực hiện và giải thích: map, flatMap, filter, distinct, reduceByKey, sortByKey.
33. Bài mở rộng: so sánh groupByKey() và reduceByKey(); phương pháp nào phù hợp Big Data hơn và vì sao?

**BÀI 3. PYSPARK DATAFRAME VÀ SPARK SQL****Bài 3.1. Đọc FIFA 2018**

```
df = spark.read.option('header', True).option('inferSchema', True).csv('Datasets/Fifa2018_dataset.csv')
```

34. Xác định số dòng, số cột.
35. In schema và danh sách cột.
36. Xác định số lượng giá trị thiếu của từng cột.

**Bài 3.2. Khám phá dữ liệu**

37. Hiển thị 20 cầu thủ đầu tiên.
38. Lọc Overall > 85.
39. Lọc Age < 21.
40. Lọc Potential > 90.

**Bài 3.3. Select, Filter và OrderBy**

41. 10 cầu thủ có Overall cao nhất.
42. 10 cầu thủ trẻ có Potential cao nhất.
43. Cầu thủ Brazil và Argentina.
44. Cầu thủ Overall >= 85 và Age < 25.

**Bài 3.4. GroupBy và Aggregate**

45. 10 quốc gia có nhiều cầu thủ nhất.
46. Tính Average Overall, Average Potential, Average Age theo quốc gia.

**Bài 3.5. Phân tích câu lạc bộ**

- 47. 10 câu lạc bộ có nhiều cầu thủ nhất.
- 48. Overall trung bình theo câu lạc bộ.
- 49. Potential trung bình và tuổi trung bình theo câu lạc bộ.

**Câu hỏi:** Overall trung bình cao có đồng nghĩa Potential trung bình cao không?

**Bài 3.6. Spark SQL**

```
df.createOrReplaceTempView('fifa')
```

- 50. Hiển thị 10 bản ghi đầu.
- 51. 10 cầu thủ Overall cao nhất.
- 52. Overall trung bình theo quốc gia.
- 53. 10 quốc gia có Overall trung bình cao nhất.
- 54. Cầu thủ Age < 21 và Potential >= 85.

**Bài 3.7. So sánh DataFrame API và Spark SQL**

- 55. Thực hiện cùng một yêu cầu bằng DataFrame API và Spark SQL, so sánh kết quả và khả năng đọc code.

**BÀI 4. MACHINE LEARNING VỚI PYSPARK****Phần A. K-Means Clustering**

```
Dataset: Datasets/5000_points.txt
```

- 56. Đọc dữ liệu thành DataFrame x, y.
- 57. Kiểm tra schema, missing value và dữ liệu bất thường.
- 58. Dùng VectorAssembler tạo cột features.
- 59. Huấn luyện KMeans với k từ 2 đến 20.
- 60. Tính Silhouette bằng ClusteringEvaluator.
- 61. Chọn k phù hợp và trực quan hóa cluster.

| K   | Silhouette |
|-----|------------|
| 2   | ...        |
| 3   | ...        |
| ... | ...        |
| 20  | ...        |

**Câu hỏi:** vì sao không nên gọi toPandas() trên toàn bộ DataFrame rất lớn?

**Phần B. Phân loại Spam/Ham**

```
Datasets: spam.txt và ham.txt
```

- 62. Tạo DataFrame gồm text và label (1 = spam, 0 = ham).
- 63. Xây pipeline Tokenizer -> StopWordsRemover -> HashingTF -> IDF.
- 64. Chia train/test 80/20.
- 65. Huấn luyện LogisticRegression.

66. Đánh giá Accuracy, Precision, Recall, F1 và ROC-AUC.

**Câu hỏi:** Accuracy có luôn là metric tốt nhất cho bài toán spam không?

## BÀI THỰC HÀNH TỔNG HỢP

- Chọn dataset tối thiểu 100.000 dòng.
- Trình bày nguồn, kích thước, schema và missing values.
- Sử dụng tối thiểu: select, filter, withColumn, groupBy, agg, orderBy.
- Viết tối thiểu 5 truy vấn Spark SQL có ý nghĩa.
- Đặt tối thiểu 5 câu hỏi phân tích dữ liệu.
- Thực hiện ít nhất một bài toán Classification, Regression hoặc Clustering bằng pyspark.ml.

## 3. NỘI DUNG VÀ ÔN TẬP

### SẢN PHẨM NỘI

MSSV\_HoTen\_BigDataPySpark/  
 ├── BigData\_PySpark.ipynb  
 ├── report.pdf  
 ├── README.md  
 └── dataset/

### Thang điểm gợi ý

| Nội dung                            | Điểm |
|-------------------------------------|------|
| Khởi tạo và đọc dữ liệu bằng Spark  | 1.0  |
| Tiền xử lý dữ liệu                  | 1.5  |
| RDD/DataFrame transformations       | 1.5  |
| Spark SQL                           | 1.5  |
| Phân tích dữ liệu                   | 1.5  |
| Machine Learning                    | 1.5  |
| Trực quan hóa và giải thích kết quả | 1.0  |
| Trình bày notebook/code             | 0.5  |
| Tổng                                | 10.0 |

### Câu hỏi kiểm tra cuối bài

1. Apache Spark khác Pandas ở điểm nào?
2. RDD là gì?
3. DataFrame khác RDD như thế nào?
4. Partition dùng để làm gì?
5. Transformation là gì?
6. Action là gì?
7. Lazy Evaluation là gì?
8. map() và flatMap() khác nhau thế nào?
9. reduceByKey() khác groupByKey() thế nào?
10. Spark SQL có ưu điểm gì?
11. Tại sao không nên dùng collect() với dữ liệu rất lớn?

12. Tại sao không nên chuyển toàn bộ Spark DataFrame sang Pandas?
13. Spark có tính toán ngay khi gọi filter() không?
14. cache() có tác dụng gì?
15. PySpark phù hợp với các bài toán nào?

---o0o---