BÀI TẬP TÌNH HUỐNG
BIG DATA ANALYTICS WITH PYSPARK

1. Mục tiêu

- Khởi tạo và làm việc với SparkSession, DataFrame và Spark SQL.
- Hiểu Transformation, Action, Lazy Evaluation và execution plan.
- Thực hiện data profiling, data cleaning và xử lý dữ liệu lớn bằng PySpark.
- Kết hợp nhiều bảng bằng join; thực hiện aggregation và Window Functions.
- Hiểu partition, shuffle, cache và cách xuất dữ liệu dạng Parquet.
- Chuyển kết quả kỹ thuật thành insight phục vụ phân tích kinh doanh.

2. Dữ liệu thực hành

Bộ dữ liệu mô phỏng hành vi thương mại điện tử gồm khoảng 300.000 sự kiện trong giai đoạn 2024–2025, 25.000 khách hàng và 500 sản phẩm. Dữ liệu có missing, duplicate và một số giá trị bất thường có chủ đích.

File	Nội dung	Quy mô
ecommerce_events_dirty.csv	Sự kiện view/cart/purchase/return	~300K dòng
customers.csv	Thông tin khách hàng	25K
products.csv	Thông tin sản phẩm	500

3. Nội dung thực hành

Phần A: Spark Environment & Data Understanding

- Khởi tạo SparkSession; kiểm tra Spark version, master và default parallelism.
- Đọc 3 file CSV bằng Spark DataFrame; kiểm tra schema, số dòng, số cột.
- Thống kê EventType, số khách hàng/sản phẩm distinct và thống kê mô tả.

Phần B: Data Quality & Cleaning

- Đếm missing values và duplicate.
- Phát hiện UnitPrice <= 0, Discount ngoài [0,1], Quantity = 0.
- Thiết kế quy tắc làm sạch và giải thích tại sao return có Quantity âm không nhất thiết là dữ liệu sai.

Phần C: Transformation, Action & Lazy Evaluation

- Xây dựng chuỗi filter → withColumn → select.
- Phân biệt Transformation với Action.
- Sử dụng explain(mode='formatted') để quan sát execution plan.

Phần D: DataFrame Analytics

- Tính Purchase Events, Customers, Products, Units, Revenue và Average Event Value.

- Phân tích doanh thu theo tháng, kênh, giờ và loại sự kiện.
- Trả lời các câu hỏi kinh doanh bằng DataFrame API.

Phần E: Join & Spark SQL

- Join events với customers và products để tạo bảng Events 360.
- Phân tích Region, Category, Brand, CustomerTier và Channel.
- Viết tối thiểu 5 câu truy vấn Spark SQL có WHERE, GROUP BY, ORDER BY và aggregation.

Phần F: Window Functions

- Dùng lag() để xác định lần mua trước.
- Tính số ngày giữa các lần mua.
- Xếp hạng sản phẩm trong từng Category và tính cumulative revenue.

Phần G: Performance

- Thực hành repartition(), coalesce(), cache() và explain().
- Thảo luận shuffle, driver memory và rủi ro của collect().
- Xuất dữ liệu dạng Parquet có partition.

Phần H: Mini Analytics Pipeline

- Tạo bảng summary theo YearMonth × Region × Category × Channel.
- Tính Revenue, Units, PurchaseEvents, Customers và RevenuePerCustomer.
- Viết 5 insight và 3 đề xuất kinh doanh.

4. Câu hỏi bắt buộc

1. Spark DataFrame khác Pandas DataFrame ở điểm nào quan trọng nhất?
2. Transformation và Action khác nhau như thế nào?
3. Lazy Evaluation mang lại lợi ích gì?
4. Shuffle là gì và tại sao shuffle thường tốn chi phí?
5. `repartition()` khác `coalesce()` như thế nào?
6. Khi nào nên sử dụng `cache()`?
7. Tại sao không nên dùng `collect()` với dữ liệu lớn?
8. Vì sao Parquet thường phù hợp hơn CSV cho analytics?
9. Spark có luôn nhanh hơn Pandas không? Giải thích.
10. Khi nào không nên dùng Spark?

5. Sản phẩm nộp

- `BigDataPySpark_HoTen_MSSV.ipynb` đã chạy đầy đủ.
- Data Quality Report: ít nhất 5 vấn đề dữ liệu.
- 5 KPI, 5 Spark SQL queries, 3 phân tích Join, 2 phân tích Window.
- Kết quả thử nghiệm cache/partition và file Parquet đầu ra.

- 5 business insights và 3 đề xuất kinh doanh.

6. Thang điểm gợi ý

Nội dung	**Điểm**
Spark & Data Understanding	1.0
Data Quality & Cleaning	1.5
DataFrame Analytics	1.5
Join & Spark SQL	2.0
Window Functions	1.0
Partition / Cache / Parquet	1.0
Mini Analytics Pipeline	1.0
Business Insights & trình bày	1.0

Lưu ý: Không sử dụng collect() để đưa toàn bộ dữ liệu lớn về driver. Mọi insight phải kèm số liệu hoặc kết quả truy vấn có thể kiểm chứng.

---o0o---

(Hết)