BÀI TẬP TÌNH HUỐNG

CUSTOMER & SALES ANALYTICS WITH PYSPARK

1. Mục tiêu

- Xử lý dữ liệu giao dịch lớn bằng PySpark DataFrame và Spark SQL.
- Xây dựng KPI bán hàng và khách hàng phục vụ quyết định kinh doanh.
- Thực hiện Customer 360, RFM, repeat purchase và K-Means segmentation.
- Phân tích Pareto 80/20, cohort/retention và chuyển kết quả thành business insights.
- Pipeline: Raw Transactions → Data Quality → Sales KPI → Customer 360 → RFM → Segmentation → Retention/Pareto → Business Insights

2. Dataset

Bộ dữ liệu mô phỏng phục vụ giảng dạy, giai đoạn 2023–2025, gồm khoảng 180.000 giao dịch, 12.000 khách hàng và 100 sản phẩm. Dữ liệu có missing values và duplicate có chủ đích để sinh viên thực hành Data Quality.

File	Vai trò	Nội dung
sales_transactions_dirty.csv	Fact giao dịch	Order, Customer, Product, Channel, Revenue, Profit, ...
customers.csv	Thông tin khách hàng	Segment, Region, SignupDate
products.csv	Thông tin sản phẩm	ProductName, Category, Cost, ListPrice

3. Nội dung thực hành

Phần A: Data Understanding & Cleaning

- Xác định grain, số dòng/đơn hàng/khách hàng/sản phẩm và khoảng thời gian.
- Audit missing, duplicate, Quantity/Price/Discount bất thường.
- Xây dựng quy tắc cleaning và giải thích tác động đến KPI.

Phần B: Sales Analytics

- Tính Revenue, Profit, Units Sold, Orders, Customers, AOV, Margin, Revenue/Customer, Items/Order, Return Rate.
- Phân tích theo tháng và tính tăng trưởng MoM bằng Window.
- So sánh Product, Category, Channel, Region và Customer Segment.

Phần C: Customer 360 & Repeat Purchase

- Tạo bảng Customer 360: First/Last Purchase, Orders, Units, Revenue, Profit, AOV, Distinct Products.
- Tính repeat customer rate và khoảng cách trung bình giữa các lần mua.
- So sánh khách hàng doanh thu cao với khách hàng lợi nhuận cao.

Phần D: RFM & Segmentation

- Tính Recency, Frequency, Monetary.

- Chấm điểm RFM và gán Champions/Loyal/Potential/At Risk/Lost.
- Chuẩn hóa RFM và phân cụm K-Means; chọn k bằng Silhouette Score.
- Profile cluster và đề xuất hành động marketing.

Phần E: Pareto & Retention

- Xác định % khách hàng tạo ra 50%, 80%, 90% doanh thu.
- Lặp lại Pareto cho sản phẩm.
- Bài nâng cao: cohort theo tháng mua đầu tiên và retention theo MonthIndex.

Phần F: Spark SQL & Business Insight

- Viết tối thiểu 6 truy vấn Spark SQL.
- Rút ra ít nhất 5 insight có số liệu và 3 recommendation.
- Nêu tối thiểu 2 hạn chế của dữ liệu/phân tích.

4. Bài tập mở rộng

Câu hỏi kinh doanh trọng tâm

1. Doanh thu/lợi nhuận tăng trưởng theo thời gian như thế nào? Có seasonality không?
2. Category/kênh/vùng nào tạo nhiều doanh thu nhưng margin thấp?
3. Khách hàng nào tạo giá trị lớn nhất? Revenue cao có đồng nghĩa Profit cao?
4. Tỷ lệ khách hàng quay lại là bao nhiêu? Khoảng cách giữa các lần mua?
5. Nhóm RFM/cluster nào nên ưu tiên giữ chân hoặc tái kích hoạt?
6. Doanh nghiệp có phụ thuộc quá mức vào top khách hàng/sản phẩm không?

Sản phẩm nộp

- Notebook đã chạy đầy đủ.
- Báo cáo 2-4 trang hoặc slide tóm tắt.
- Bảng RFM/segmentation và biểu đồ minh họa phù hợp.
- 5 business insights có số liệu minh chứng + 3 recommendations.

5. Rubric gợi ý

Nội dung	Điểm
Data Understanding & Cleaning	1.5
Sales KPI & Trend	2.0
Customer 360 & Repeat Purchase	1.5
RFM & K-Means	2.0
Pareto/Cohort/Spark SQL	1.5
Business Insights & Recommendations	1.0
Trình bày & tái lập kết quả	0.5
Tổng	10.0

Yêu cầu quan trọng

Mỗi kết luận phải được hỗ trợ bởi kết quả tính toán từ PySpark. Không chấp nhận insight chỉ dựa trên cảm nhận hoặc biểu đồ không có số liệu đối chiếu. Khi dùng AI hỗ trợ viết code/giải thích, sinh viên vẫn phải tự chạy, kiểm chứng và chịu trách nhiệm về kết quả.

---o0o---

(Hết)