BÀI TẬP TÌNH HUỐNG

BUSINESS INTELLIGENCE: PYSPARK + POWER BI

1. Mục tiêu

- Sử dụng PySpark để ETL và tổng hợp dữ liệu giao dịch lớn.
- Thiết kế mô hình dữ liệu dạng Star Schema gồm Fact và Dimension.
- Xuất dữ liệu đã xử lý sang định dạng phù hợp để dùng trong Power BI.
- Xây dựng semantic model, relationship và DAX measures.
- Thiết kế dashboard phục vụ quyết định quản trị và trình bày insight định lượng.

2. Bối cảnh bài toán

Doanh nghiệp có dữ liệu giao dịch bán hàng với khối lượng lớn. Nhóm Data Engineering/Data Analytics sử dụng PySpark để làm sạch, chuẩn hóa và xây dựng các bảng dữ liệu phân tích. Power BI được sử dụng ở lớp Business Intelligence để mô hình hóa, tính KPI và xây dashboard cho nhà quản trị.

Pipeline: Raw Data → PySpark ETL → Fact/Dimension → Power BI Semantic Model → DAX → Dashboard → Executive Insight.

Tập dữ liệu:

Tệp	Vai trò	Nội dung
sales_transactions_dirty.csv	Raw fact	180.000+ giao dịch; có missing/duplicate có chủ đích
customers.csv	Master data	Khách hàng, segment, region, signup date
products.csv	Master data	Sản phẩm, category, cost, list price

3. Nội dung thực hành

A. PySpark ETL

1. Data Quality Audit

- Đọc dữ liệu bằng SparkSession và kiểm tra schema.
- Thống kê missing value theo cột.
- Phát hiện duplicate.
- Kiểm tra các quy tắc Quantity > 0, UnitPrice > 0, Discount hợp lệ.
- Kiểm tra Revenue với công thức nghiệp vụ và giải thích sai lệch nếu có.

2. Cleaning & Feature Engineering

- Chuẩn hóa Date; loại duplicate; xử lý missing; tạo DateKey; kiểm tra trường return; tạo các biến phục vụ KPI và BI.

3. KPI bằng PySpark

KPI	Công thức/ý nghĩa
Total Revenue	Tổng Revenue

Total Profit	Tổng Profit
Total Orders	Distinct OrderID
Total Customers	Distinct CustomerID
AOV	Revenue / Orders
Profit Margin	Profit / Revenue
Return Rate	Tỷ lệ dòng giao dịch trả hàng

Phần B. Xây dựng Star Schema

Cho bảng mô tả:

Bảng	Grain / chức năng
FactSales	Một dòng giao dịch sản phẩm trong đơn hàng
DimDate	Ngày và thuộc tính thời gian
DimCustomer	Thông tin khách hàng
DimProduct	Thông tin sản phẩm
DimChannel	Kênh bán hàng

Yêu cầu: relationship Many-to-One từ FactSales sang các Dimension; filter direction một chiều từ Dimension → Fact. Sinh viên phải giải thích grain của FactSales và lý do không nên lặp thuộc tính mô tả trong Fact.

C. Xuất dữ liệu cho Power BI

- Xuất Fact/Dim dưới dạng CSV để kiểm tra và import nhanh.
- Xuất Parquet để minh họa pipeline dữ liệu lớn và định dạng columnar.
- Kiểm tra row count và uniqueness của khóa dimension trước khi import.
- Lưu kết quả trong thư mục bi_output/.

D. Power BI Semantic Model & DAX

Trong Power BI Desktop, nạp FactSales và các Dim, thiết lập relationship, Mark as Date Table cho DimDate và tạo các explicit measures.

Measure bắt buộc	Mục đích
Total Revenue / Total Profit	KPI tài chính
Total Orders / Customers	Quy mô hoạt động
Average Order Value	Giá trị đơn trung bình
Profit Margin %	Hiệu quả lợi nhuận
Revenue YoY %	Tăng trưởng năm
Revenue YTD	Lũy kế năm

Return Rate %	Chất lượng doanh thu

Phần E. Dashboard

Dashboard 1: Executive Sales Overview

KPI cards: Revenue, Profit, Margin, Orders, Customers, AOV; line chart Revenue/Profit theo tháng; revenue theo Category/Region; slicer Year, Region, Channel, Category.

Dashboard 2: Product & Customer Performance

Top 10 sản phẩm; customer segment; Pareto; return rate; matrix Category × Region.

Dashboard 3: Management Insight

Sinh viên tự xây dashboard trả lời ít nhất 5 câu hỏi kinh doanh; mỗi visual phải có insight và action recommendation.

4. Bài tập mở rộng

Câu hỏi phân tích bắt buộc

- Kênh bán hàng nào tăng trưởng nhanh nhất?
- Nhóm sản phẩm nào doanh thu cao nhưng margin thấp?
- Khu vực nào có Return Rate cao?
- Top khách hàng đóng góp bao nhiêu % doanh thu?
- Doanh thu có tính mùa vụ không?
- Có trade-off nào giữa tăng trưởng và lợi nhuận?
- Nếu chỉ được chọn 3 KPI cho Ban giám đốc, chọn gì và vì sao?

Thảo luận Big Data / BI Architecture

So sánh hai cách: (1) Raw CSV → Power BI xử lý toàn bộ; (2) Raw Data → PySpark ETL → Fact/Dim → Power BI. Phân tích theo các tiêu chí volume, refresh time, reproducibility, governance, maintainability và separation of concerns.

Yêu cầu nộp bài

- Notebook .ipynb đã chạy đầy đủ.
- File Power BI .pbix.
- PDF/ảnh dashboard.
- Báo cáo 2–4 trang gồm KPI, insight và recommendation.
- Thư mục bi_output/ hoặc đường dẫn dữ liệu.
- README ngắn mô tả cách chạy.

Rubric (10 điểm)

Nội dung	Điểm
PySpark data quality & cleaning	1.5
Star Schema & export	1.5

Power BI model & relationships	1.5
DAX measures	1.5
Dashboard design	2.0
Business insights & recommendations	1.5
Trình bày / reproducibility	0.5

Tài liệu tham khảo

- Microsoft – Understand star schema and the importance for Power BI: https://learn.microsoft.com/power-bi/guidance/star-schema
- Microsoft – Power BI Guidance: https://learn.microsoft.com/power-bi/guidance/
- Apache Spark SQL/DataFrame documentation: https://spark.apache.org/docs/latest/sql-programming-guide.html

---o0o---

(Hết)